

Aula 6: Modelos de espaço de estados

Marcus L. Nascimento

1 de dezembro de 2025

1. Introdução

2. Filtro de Kalman

3. Modelos relacionados

Introdução

- Modelos de espaço de estados podem ser aplicados tanto quando a variável aleatória Y_t é unidimensional quanto quando Y_t é um vetor de dimensão k .
 - Tempo (t) discreto, $t = 1, 2, \dots, n$
- Modelos de espaço de estados são determinados por duas equações:

$$Y_t = F_t(X_t, W_t) \text{ (Equação de observação)}$$

$$X_t = G_t(X_{t-1}, V_t) \text{ (Equação de evolução),}$$

onde X_t é um vetor de dimensão d e W_t e V_t são ruídos aleatórios.

- **Equação de evolução** ($X_t = G_t(X_{t-1}, V_t)$):
 - Descreve a evolução temporal do estado X_t no sistema.
- **Equação de observação** ($Y_t = F_t(X_t, W_t)$):
 - A dimensão k de Y_t é, tipicamente, menor que a dimensão d de X_t .
- **Inferência sequencial**: Estima o estado presente X_t do sistema dinâmico utilizando o histórico $\mathcal{J}_t = (y_1, y_2, \dots, y_t)$.




Figura: Estrutura de independência condicional.

- Para qualquer tempo t e quaisquer valores y_1, y_2, \dots, y_t , estamos interessados em encontrar estimativas para
 - O vetor de estados X_t no mesmo instante de tempo - **Problema de Filtragem**;
 - Os estados futuros X_{t+l} do sistema para $l > 0$ - Problema de Previsão;
 - Uma ocorrência passada do vetor de estados X_m , $m < t$ - Problema de Suavização.

Filtro de Kalman

- Estimadores “ótimos”:
 - Perda absoluta: mediana;
 - Perda quadrática: média;
 - Perda 0-1: moda.
- O **filtro de Kalman** aplica a média condicional como estimador para o estado:

$$\hat{x}_t^+ = E(X_t | \mathcal{J}_t) = \int x_t f(x_t | \mathcal{J}_t) dx_t.$$

- Para uma melhor compreensão do estimador, exploramos a densidade $f(x_t|\mathcal{J}_t)$:

$$\begin{aligned}f(x_t|\mathcal{J}_t) &= \frac{f(\mathcal{J}_t|x_t)f(x_t)}{f(\mathcal{J}_t)} \text{ (Regra de Bayes)} \\&= \frac{f(y_t, \mathcal{J}_{t-1}|x_t)f(x_t)}{f(y_t, \mathcal{J}_{t-1})} \quad (\mathcal{J}_t = (y_t, \mathcal{J}_{t-1})) \\&= \frac{f(y_t|\mathcal{J}_{t-1}, x_t)f(\mathcal{J}_{t-1}|x_t)f(x_t)}{f(y_t|\mathcal{J}_{t-1})f(\mathcal{J}_{t-1})} \quad (f(a, b) = f(a|b)f(b)) \\&= \frac{f(y_t|\mathcal{J}_{t-1}, x_t)[f(x_t|\mathcal{J}_{t-1})f(\mathcal{J}_{t-1})]f(x_t)}{f(y_t|\mathcal{J}_{t-1})[f(x_t)]f(\mathcal{J}_{t-1})} \text{ (Regra de Bayes)} \\&= \frac{f(y_t|\mathcal{J}_{t-1}, x_t)f(x_t|\mathcal{J}_{t-1})}{f(y_t|\mathcal{J}_{t-1})} \\&= \frac{f(y_t|x_t)f(x_t|\mathcal{J}_{t-1})}{f(y_t|\mathcal{J}_{t-1})} \text{ (Independência condicional).} \tag{1}\end{aligned}$$

- A Equação (1) mostra que podemos computar a densidade desejada em dois passos:
 1. Computar a densidade para previsão de X_t condicional nas observações passadas:

$$f(x_t|\mathcal{J}_{t-1}) = \int f(x_t|x_{t-1})f(x_{t-1}|\mathcal{J}_{t-1})dx_{t-1}.$$

2. Atualizar a previsão via

$$f(x_t|\mathcal{J}_t) = \frac{f(y_t|x_t)f(x_t|\mathcal{J}_{t-1})}{f(y_t|\mathcal{J}_{t-1})},$$

onde $f(y_t|\mathcal{J}_{t-1}) = \int f(y_t|x_{t-1})f(x_{t-1}|\mathcal{J}_{t-1})dx_{t-1}$.

- A solução para o procedimento de inferência sequencial consiste em prever/atualizar.

Hipótese de Normalidade

- Soluções em forma fechada para as integrais anteriores não podem ser encontradas em muitos problemas reais.
 - Soluções simplificadas podem ser obtidas supondo que as densidades sejam gaussianas.
- Defina:
 - Erro de previsão: $\tilde{x}_t^- = x_t - \hat{x}_t^-$, onde $\hat{x}_t^- = E(X_t | \mathcal{J}_{t-1})$.

$$\begin{aligned} E(\tilde{x}_t^-) &= E(x_t) - E(\hat{x}_t^-) = E(x_t) - E(E(x_t | \mathcal{J}_{t-1})) = 0 \\ E(\tilde{x}_t^- | \mathcal{J}_{t-1}) &= E(x_t - E(x_t | \mathcal{J}_{t-1}) | \mathcal{J}_{t-1}) = E(x_t | \mathcal{J}_{t-1}) - E(x_t | \mathcal{J}_{t-1}) = 0 = E(\tilde{x}_t^-) \end{aligned}$$

- Inovação: $\tilde{y}_t = y_t - \hat{y}_t$, onde $\hat{y}_t = E(Y_t | \mathcal{J}_{t-1})$.

$$E(\tilde{y}_t) = E(y_t) - E(\hat{y}_t) = E(y_t) - E(E(y_t | \mathcal{J}_{t-1})) = 0$$

Hipótese de Normalidade

- Objeto de interesse: $\hat{x}_t^+ = E(X_t | \mathcal{J}_t)$.

A partir do erro de previsão, temos:

$$E(\tilde{x}_t^- | \mathcal{J}_t) = \underbrace{E(x_t | \mathcal{J}_t)}_{\hat{x}_t^+} - \underbrace{E(\hat{x}_t^- | \mathcal{J}_t)}_{\hat{x}_t^-}.$$

Em contrapartida, podemos escrever:

$$E(\tilde{x}_t^- | \mathcal{J}_t) = E(\tilde{x}_t^- | y_t, \mathcal{J}_{t-1}) = E(\tilde{x}_t^- | y_t).$$

Logo,

$$\hat{x}_t^+ = \hat{x}_t^- + E(\tilde{x}_t^- | y_t), \quad (2)$$

onde o procedimento de inferência sequencial consiste novamente em prever/atualizar.

Hipótese de Normalidade

- Na Equação (2), precisamos caracterizar $E(\tilde{x}_t^- | y_t)$.
 - Assumiremos que a distribuição conjunta é normal.

Tomando

$$\begin{bmatrix} X \\ Y \end{bmatrix} \text{ com média } \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} \text{ e covariância } \begin{bmatrix} \Sigma_x & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_y \end{bmatrix},$$

temos:

$$f(x|y) \sim N(\mu_x + \Sigma_{xy}\Sigma_y^{-1}(y - \mu_y), \Sigma_x - \Sigma_{xy}\Sigma_y^{-1}\Sigma_{yx}).$$

Logo,

$$E(X|Y) = \mu_x + \Sigma_{xy}\Sigma_y^{-1}(y - \mu_y).$$

Hipótese de Normalidade

- Retornando para $E(\tilde{x}_t^- | y_t)$ e observando que $y_t = \tilde{y}_t + \hat{y}_t$, temos:

$$\begin{aligned} E(\tilde{x}_t^- | y_t) &= E(\tilde{x}_t^- | \tilde{y}_t + \hat{y}_t) \\ &= E(\tilde{x}_t^-) + \Sigma_{\tilde{x}\tilde{y},t}^- \Sigma_{\tilde{y},t}^{-1} (\tilde{y}_t + \hat{y}_t - E(\tilde{y}_t + \hat{y}_t)) \\ &= 0 + \Sigma_{\tilde{x}\tilde{y},t}^- \Sigma_{\tilde{y},t}^{-1} (\tilde{y}_t + \hat{y}_t - (0 + \hat{y}_t)) \\ &= \underbrace{\Sigma_{\tilde{x}\tilde{y},t}^- \Sigma_{\tilde{y},t}^{-1}}_{L_t} \tilde{y}_t. \end{aligned}$$

- Reescrevendo a Equação (2), temos a seguinte equação de atualização:

$$\hat{x}_t^+ = \hat{x}_t^- + L_t \tilde{y}_t.$$

Hipótese de Normalidade

- A incerteza associada a \hat{x}_t^+ pode ser mensurada através da matriz de covariância $\Sigma_{\tilde{x},t}^+$:

$$\begin{aligned}\Sigma_{\tilde{x},t}^+ &= E(\tilde{x}_t^+ \tilde{x}_t^{+'}) \\&= E((x_t - \hat{x}_t^+)(x_t - \hat{x}_t^+)') \\&= E([(x_t - \hat{x}_t^-) - L_t \tilde{y}_t][(x_t - \hat{x}_t^-) - L_t \tilde{y}_t]') \\&= E((\tilde{x}_t^- - L_t \tilde{y}_t)(\tilde{x}_t^- - L_t \tilde{y}_t)') \\&= \Sigma_{\tilde{x},t}^- - L_t \underbrace{E(\tilde{y}_t \tilde{x}_t^{-'})}_{\Sigma_{\tilde{y},t} L_t'} - \underbrace{E(\tilde{x}_t^- \tilde{y}_t')}_{L_t \Sigma_{\tilde{y},t}} L_t' + L_t \Sigma_{\tilde{y},t} L_t' \\&= \Sigma_{\tilde{x},t}^- - L_t \Sigma_{\tilde{y},t} L_t'.\end{aligned}$$

Hipótese de Normalidade

- O Filtro de Kalman pode, portanto, ser descrito através dos seguintes passos:
 - **Definições:** $\tilde{x}_t^- = x_t - \hat{x}_t^-$ e $\tilde{y}_t = y_t - \hat{y}_t$, onde $\hat{x}_t^- = E(x_t | \mathcal{J}_{t-1})$ e $\hat{y}_t = E(y_t | \mathcal{J}_{t-1})$.
 - **Inicialização:** Para $t = 0$, $\hat{x}_0^+ = E(x_0)$ e $\Sigma_{\tilde{x},0}^+ = E((x_0 - \hat{x}_0^+)(x_0 - \hat{x}_0^+)')$.
 - **Inferência sequencial:** Para $t = 1, 2, \dots, n$, calcule
 - 1a. $\hat{x}_t^- = E(x_t | \mathcal{J}_{t-1}) = E(G_t(x_{t-1}, v_t) | \mathcal{J}_{t-1})$;
 - 1b. $\Sigma_{\tilde{x},t}^- = E(\tilde{x}_t^- \tilde{x}_t^{-'}) = E((x_t - \hat{x}_t^-)(x_t - \hat{x}_t^-)')$;
 - 1c. $\hat{y}_t = E(y_t | \mathcal{J}_{t-1}) = E(F_t(x_t, w_t) | \mathcal{J}_{t-1})$;
 - 2a. $L_t = E(\tilde{x}_t^- \tilde{y}_t') [E(\tilde{y}_t \tilde{y}_t')]^{-1}$;
 - 2b. $\hat{x}_t^+ = \hat{x}_t^- + L_t(y_t - \hat{y}_t)$
 - 2c. $\Sigma_{\tilde{x},t}^+ = E(\tilde{x}_t^+ \tilde{x}_t^{+'}) = E((x_t - \hat{x}_t^+)(x_t - \hat{x}_t^+)') = \Sigma_{\tilde{x},t}^- - L_t \Sigma_{\tilde{y},t} L_t'$.

- **Equação de evolução** ($X_t = G_t(X_{t-1}, V_t)$):
 - $X_t = G_t(X_{t-1}, V_t) = G_t X_{t-1} + V_t$, onde G_t é uma matriz de dimensão $d \times d$.
 - V_t denota o erro de evolução:
 - Média 0 e covariância Σ_v ;
 - Assume-se que V_t é independente de X_m para todo $m < t$.
 - Na maioria dos casos, a matriz G_t será independente de t .

Hipótese de Linearidade

- **Equação de observação** ($Y_t = F_t(X_t, W_t)$):
 - $Y_t = F_t(X_t, W_t) = F_t X_t + W_t$, onde F_t é uma matriz de dimensão $k \times k$.
 - W_t denota o erro observacional:
 - Média 0 e variância Σ_w ;
 - Supõe-se que os erros observacionais e de evolução sejam independentes.
 - Na maioria dos casos, o vetor F_t será independente de t .

Hipótese de Linearidade

- No caso linear, pode ser provado que o Filtro de Kalman é ótimo (menor erro quadrático médio) e o estimador de máxima verossimilhança.
- V_t e W_t são ruídos brancos mutuamente independentes:

$$E(W_t W_s') = \begin{cases} \Sigma_w, t = s \\ 0, t \neq s \end{cases} \quad E(V_t V_s') = \begin{cases} \Sigma_v, t = s \\ 0, t \neq s \end{cases}$$

- Apesar de as hipóteses de linearidade e independência não serem normalmente observadas na prática, há consenso, tanto na prática quanto na literatura, de que o método ainda assim funciona bastante bem.
- A seguir, traduziremos os passos 1a, 1b, 1c, 2a, 2b e 2c do Filtro de Kalman para o caso linear.

Hipótese de Linearidade

Filtro de Kalman: 1a.

$$\begin{aligned}\hat{x}_t^- &= E(x_t | \mathcal{J}_{t-1}) \\ &= E(G_t x_{t-1} + v_t | \mathcal{J}_{t-1}) \\ &= E(G_t x_{t-1} | \mathcal{J}_{t-1}) + E(v_t | \mathcal{J}_{t-1}) \\ &= G_t \hat{x}_{t-1}^+\end{aligned}$$

Filtro de Kalman: 1b.

$$\begin{aligned}\tilde{x}_t^- &= x_t - \hat{x}_t^- \\ &= G_t x_{t-1} + v_t - G_t \hat{x}_{t-1}^+ \\ &= G_t \tilde{x}_{t-1}^+ + v_t \\ \Sigma_{\tilde{x},t}^- &= E((G_t \tilde{x}_{t-1}^+ + v_t)(G_t \tilde{x}_{t-1}^+ + v_t)') \\ &= E(G_t \tilde{x}_{t-1}^+ \tilde{x}_{t-1}^{+'} G_t' + G_t \tilde{x}_{t-1}^+ v_t' + v_t \tilde{x}_{t-1}^{+'} G_t' + v_t v_t') \\ &= G_t \Sigma_{\tilde{x},t-1}^+ G_t' + \Sigma_v\end{aligned}$$

Hipótese de Linearidade

Filtro de Kalman: 1c.

$$\begin{aligned}\hat{y}_t &= E(F_t x_t + w_t | \mathcal{J}_{t-1}) \\ &= E(F_t x_t | \mathcal{J}_{t-1}) + E(w_t | \mathcal{J}_{t-1}) \\ &= F_t \hat{x}_t^-\end{aligned}$$

Filtro de Kalman: 2a. ($L_t = \Sigma_{\tilde{x}\tilde{y},t}^- \Sigma_{\tilde{y},t}^{-1}$).

Primeiro, focaremos em $\Sigma_{\tilde{y},t}$:

$$\begin{aligned}\tilde{y}_t &= y_t - \hat{y}_t \\ &= F_t x_t + w_t - F_t \hat{x}_t^- \\ &= F_t \tilde{x}_t^- + w_t \\ \Sigma_{\tilde{y},t} &= E((F_t \tilde{x}_t^- + w_t)(F_t \tilde{x}_t^- + w_t)') \\ &= E(F_t \tilde{x}_t^- \tilde{x}_t^{-'} F_t' + F_t \tilde{x}_t^- w_t' + w_t \tilde{x}_t^{-'} F_t' + w_t w_t') \\ &= F_t \Sigma_{\tilde{x},t}^- F_t' + \Sigma_w\end{aligned}$$

Hipótese de Linearidade

Para $\Sigma_{\tilde{x}\tilde{y},t}^-$, temos:

$$\begin{aligned}\Sigma_{\tilde{x}\tilde{y},t}^- &= E(\tilde{x}_t^- \tilde{y}_t') \\ &= E(\tilde{x}_t^- (F_t \tilde{x}_t^- + w_t)') \\ &= E(\tilde{x}_t^- \tilde{x}_t^{-'} F_t' + \tilde{x}_t^- w_t') \\ &= \Sigma_{\tilde{x},t}^- F_t'\end{aligned}$$

Por fim,

$$L_t = \Sigma_{\tilde{x},t}^- F_t' [F_t \Sigma_{\tilde{x},t}^- F_t' + \Sigma_w]^{-1}$$

Filtro de Kalman: 2b.

$$\hat{x}_t^+ = \hat{x}_t^- + L_t(y_t - \hat{y}_t)$$

Filtro de Kalman: 2c.

$$\begin{aligned}\Sigma_{\tilde{x},t}^+ &= \Sigma_{\tilde{x},t}^- - L_t \Sigma_{\tilde{y},t} L_t' \\ &= \Sigma_{\tilde{x},t}^- - L_t \Sigma_{\tilde{y},t} \Sigma_{\tilde{y},t}^{-1} \Sigma_{\tilde{x}\tilde{y},t}' \\ &= \Sigma_{\tilde{x},t}^- - L_t F_t \Sigma_{\tilde{x},t}^- \\ &= (I - L_t F_t) \Sigma_{\tilde{x},t}^-\end{aligned}$$

Hipótese de Linearidade

- No caso linear, o Filtro de Kalman pode, portanto, ser descrito através dos seguintes passos:

- Definições:** $\tilde{x}_t^- = x_t - \hat{x}_t^-$ e $\tilde{y}_t = y_t - \hat{y}_t$, onde $\hat{x}_t^- = E(x_t | \mathcal{J}_{t-1})$ e $\hat{y}_t = E(y_t | \mathcal{J}_{t-1})$.
- Inicialização:** Para $t = 0$, $\hat{x}_0^+ = E(x_0)$ e $\Sigma_{\tilde{x},0}^+ = E((x_0 - \hat{x}_0^+)(x_0 - \hat{x}_0^+)')$.
- Inferência sequencial:** Para $t = 1, 2, \dots, n$, calcule

1a. $\hat{x}_t^- = G_t \hat{x}_{t-1}^+$

1b. $\Sigma_{\tilde{x},t}^- = G_t \Sigma_{\tilde{x},t-1}^+ G_t' + \Sigma_v$

1c. $\hat{y}_t = F_t \hat{x}_t^-$

2a. $L_t = \Sigma_{\tilde{x},t}^- F_t' [F_t \Sigma_{\tilde{x},t}^- F_t' + \Sigma_w]^{-1}$

2b. $\hat{x}_t^+ = \hat{x}_t^- + L_t (y_t - \hat{y}_t)$

2c. $\Sigma_{\tilde{x},t}^+ = (I - L_t F_t) \Sigma_{\tilde{x},t}^-$

Modelos relacionados

- Considere a notação a seguir:
 - Y_t : série temporal univariada;
 - $X_{t1}, X_{t2}, \dots, X_{td}$: vetor de variáveis independentes (observável);
 - $X_{t1} = 1$: termo constante para todo t ;
 - $\beta_t = (\beta_{t1}, \beta_{t2}, \dots, \beta_{td})'$: vetor de coeficientes da regressão (não observável).

- Modelo de regressão linear com coeficientes variando no tempo:

$$\begin{aligned}Y_t &= F_t' \beta_t + W_t \\ \beta_t &= G \beta_{t-1} + V_t,\end{aligned}$$

onde

- $F_t = (X_{t1}, X_{t2}, \dots, X_{td})'$ e $G = I_d$;
- V_t é um escalar;
- W_t é uma matriz de dimensão $d \times s$.

Capital Asset Pricing Model (CAPM)

- Considere a notação a seguir:
 - $R_t^{(i)}$: retornos do ativo i no tempo t ;
 - $R_t^{(m)}$: retorno do mercado no tempo t - vetor com d ações.
- O modelo CAPM assume:

$$R_t^{(i)} = F_t' \beta + W_t,$$

onde $F_t = R_t^{(m)}$.

- Modelo CAPM com coeficientes variando no tempo:

$$\begin{aligned} Y_t &= F_t' \beta_t + W_t \\ \beta_t &= G \beta_{t-1} + V_t, \end{aligned}$$

onde $G = I_d$.

Modelo Autorregressivo de ordem p - $AR(p)$

Seja Y_t uma série temporal univariada, temos:

$$\begin{aligned}Y_t &= F'X_t + W_t \\X_t &= GX_{t-1} + V_t\end{aligned}$$

onde

- $X_t = (X_{t-1}, X_{t-2}, \dots, X_{t-p})'$;

- $F = (1, \underbrace{0, \dots, 0}_{p-1})'$ e $G = \begin{bmatrix} \phi_1 & \phi_2 & \phi_3 & \dots & \phi_{p-1} & \phi_p \\ 1 & 0 & 0 & \dots & 0 & 0 \\ 0 & 1 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & 0 & 0 \\ 0 & 0 & 0 & \dots & 1 & 0 \end{bmatrix}$.

Modelo Autorregressivo de ordem p - $AR(p)$

Modelo com nível variando no tempo:

- $X_t = (\mu_t, X_{t-1}, X_{t-2}, \dots, X_{t-p})'$;

- $F = (1, 1, \underbrace{0, \dots, 0}_{p-1})'$ e $G = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 & 0 \\ 0 & \phi_1 & \phi_2 & \phi_3 & \dots & \phi_{p-1} & \phi_p \\ 0 & 1 & 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & 1 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & 0 & 0 \\ 0 & 0 & 0 & 0 & \dots & 1 & 0 \end{bmatrix}$.

Modelo Autorregressivo de ordem p - AR(p)

Modelo com nível e tendência variando no tempo:

- $X_t = (\mu_t, \delta_t, X_{t-1}, X_{t-2}, \dots, X_{t-p})'$;

- $F = (1, 0, 1, \underbrace{0, \dots, 0}_{p-1})'$ e $G = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & \dots & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \phi_1 & \phi_2 & \phi_3 & \dots & \phi_{p-1} & \phi_p \\ 0 & 0 & 1 & 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \dots & 1 & 0 \end{bmatrix}$.